

SIMULAÇÃO DO TEOREMA CENTRAL DO LIMITE UTILIZANDO PYTHON

1. Introdução

A Estatística desempenha um papel fundamental na análise de dados e na tomada de decisões em diversas áreas do conhecimento. Entre seus conceitos mais importantes está o Teorema Central do Limite (TCL), que estabelece uma relação entre distribuições de probabilidade e distribuições amostrais.

O Teorema Central do Limite afirma que, independentemente da distribuição original da população, a distribuição das médias amostrais tende a se aproximar de uma distribuição normal à medida que o tamanho da amostra aumenta. Esse resultado é extremamente relevante, pois permite a aplicação de métodos estatísticos baseados na distribuição normal mesmo quando os dados originais não seguem esse comportamento.

O objetivo deste trabalho é demonstrar experimentalmente o Teorema Central do Limite por meio de simulações computacionais desenvolvidas em Python, utilizando diferentes tipos de populações e diversos tamanhos de amostra.

2. Fundamentação Teórica

2.1 População e Amostra

Em Estatística, uma população corresponde ao conjunto completo de elementos ou observações de interesse em um estudo. Já uma amostra é um subconjunto dessa população utilizado para realizar análises e inferências.

Na prática, muitas vezes não é possível estudar toda a população devido ao custo ou à quantidade de dados disponíveis. Por isso, utilizam-se amostras representativas para obter informações sobre a população.

2.2 Média Amostral

A média amostral é uma medida de tendência central calculada a partir dos elementos de uma amostra. Ela representa uma estimativa da média populacional.

Quando diferentes amostras são retiradas de uma mesma população, obtêm-se diferentes valores para a média amostral. O conjunto dessas médias forma uma nova distribuição denominada distribuição amostral da média.

2.3 Distribuição Normal

A distribuição normal é uma das distribuições de probabilidade mais importantes da Estatística. Sua representação gráfica possui formato de sino e apresenta simetria em torno da média.

Diversos fenômenos naturais, físicos e sociais podem ser modelados por distribuições normais, o que torna esse modelo amplamente utilizado em análises estatísticas.

2.4 Teorema Central do Limite

O Teorema Central do Limite estabelece que, para amostras suficientemente grandes, a distribuição das médias amostrais tende a uma distribuição normal, independentemente da forma da população original.

Dessa forma, mesmo que a população seja assimétrica ou apresente características muito diferentes da distribuição normal, as médias obtidas por meio de repetidas amostragens tendem a apresentar comportamento aproximadamente normal.

Esse resultado constitui um dos fundamentos da inferência estatística moderna.

3. Metodologia

Para verificar experimentalmente o Teorema Central do Limite, foi desenvolvido um programa em Python utilizando as bibliotecas NumPy, Matplotlib e Seaborn.

Inicialmente foram geradas populações artificiais contendo 100.000 observações para cada uma das seguintes distribuições:

- Distribuição Uniforme;
- Distribuição Exponencial;
- Distribuição Qui-Quadrado.

A escolha dessas distribuições foi realizada com o objetivo de representar populações com formatos distintos, incluindo distribuições simétricas e assimétricas.

Para cada população foram realizados os seguintes procedimentos:

1. Seleção aleatória de amostras com reposição;
2. Cálculo da média de cada amostra;
3. Repetição do processo 10.000 vezes;
4. Construção de histogramas das médias amostrais.

Os tamanhos de amostra analisados foram:

$n = 2, 5, 10, 20, 50, 100$ e 300 .

Os histogramas gerados permitiram visualizar a evolução da distribuição amostral da média conforme o tamanho da amostra aumentava.

4. Resultados e Discussão

4.1 Distribuição Uniforme

A população uniforme apresenta distribuição aproximadamente constante ao longo de seu intervalo de valores.

Observou-se que, para valores pequenos de n , a distribuição das médias ainda preservava características da população original. Entretanto, à medida que o tamanho da amostra aumentou, os histogramas passaram a apresentar formato cada vez mais próximo de uma curva normal.

Para n iguais a 50, 100 e 300, a aproximação à distribuição normal tornou-se bastante evidente.

4.2 Distribuição Exponencial

A distribuição exponencial apresenta forte assimetria positiva, concentrando grande parte dos valores próximos da origem e uma longa cauda à direita.

Mesmo partindo de uma população altamente assimétrica, verificou-se que as médias amostrais tornaram-se progressivamente mais simétricas conforme o valor de n aumentou.

Os resultados mostraram claramente a convergência para uma distribuição aproximadamente normal, constituindo uma das evidências mais importantes do Teorema Central do Limite.

4.3 Distribuição Qui-Quadrado

A distribuição qui-quadrado também apresenta assimetria positiva, embora com formato diferente da distribuição exponencial.

Assim como observado nos casos anteriores, o aumento do tamanho da amostra produziu distribuições amostrais cada vez mais simétricas e próximas de uma distribuição normal.

Esse comportamento reforça a validade do Teorema Central do Limite para diferentes tipos de populações.

4.4 Comparação dos Resultados

Ao comparar os resultados obtidos para as três distribuições analisadas, verificou-se que todas apresentaram convergência para a distribuição normal à medida que o tamanho da amostra aumentava.

Observou-se também que distribuições mais assimétricas exigiram amostras maiores para apresentar uma aproximação visual mais clara à normalidade.

Os experimentos demonstraram que o comportamento previsto pelo Teorema Central do Limite ocorre independentemente da forma inicial da população.

5. Conclusão

O presente trabalho teve como objetivo demonstrar experimentalmente o Teorema Central do Limite por meio de simulações computacionais realizadas em Python.

Foram analisadas populações com características distintas, incluindo distribuições uniforme, exponencial e qui-quadrado. Em todos os casos verificouse que a distribuição das médias amostrais tornou-se progressivamente mais próxima de uma distribuição normal à medida que o tamanho da amostra aumentava.

Os resultados obtidos confirmaram o comportamento previsto pelo Teorema Central do Limite, evidenciando sua importância para a Estatística e para a realização de inferências sobre populações a partir de amostras.

Conclui-se que o Teorema Central do Limite constitui uma das bases fundamentais da análise estatística moderna, justificando a ampla utilização da distribuição normal em diversas aplicações científicas e profissionais.

APÊNDICE A – Ferramentas Python para Análise de Dados NumPy

O NumPy é uma biblioteca destinada à computação numérica em Python. Ela fornece estruturas de dados eficientes e diversas funções matemáticas e estatísticas.

Principais aplicações:

- Manipulação de vetores e matrizes;
- Geração de números aleatórios;
- Cálculos estatísticos;
- Operações matemáticas de alto desempenho.

Pandas

O Pandas é uma biblioteca voltada para manipulação e análise de dados tabulares.

Principais aplicações:

- Leitura de arquivos CSV e Excel;
- Organização de dados em DataFrames;
- Filtragem e limpeza de dados;
- Produção de estatísticas descritivas.

Matplotlib

O Matplotlib é uma biblioteca utilizada para criação de gráficos em Python.

Principais aplicações:

- Histogramas;
- Gráficos de linha;
- Gráficos de dispersão;
- Visualização de resultados estatísticos.

Seaborn

O Seaborn é uma biblioteca baseada no Matplotlib que oferece visualizações estatísticas mais sofisticadas.

Principais aplicações:

- Histogramas com curvas de densidade;
- Gráficos estatísticos avançados;
- Melhor apresentação visual dos dados.


SciPy

O SciPy é uma biblioteca científica utilizada para análises estatísticas e matemáticas mais avançadas.


Principais aplicações:

- Testes de hipóteses;
- Distribuições de probabilidade;
- Regressão estatística;
- Métodos numéricos e otimização.


•





•



•





Código Python:

Projetos > tcl.py > ...

```
1  import numpy as np
2  import matplotlib.pyplot as plt
3  import seaborn as sns
4
5  # Reprodutibilidade
6  np.random.seed(42)
7
8  # Tamanhos das amostras
9  sample_sizes = [2, 5, 10, 20, 50, 100, 300]
10
11 # Número de amostras
12 num_samples = 10000
13
14 # Populações diferentes
15 populations = {
16     "Uniforme": np.random.uniform(0, 10, 100000),
17
18     "Exponencial": np.random.exponential(
19         scale=2,
20         size=100000
21     ),
22
23     "Qui-Quadrado": np.random.chisquare(
24         df=3,
25         size=100000
26     ),
27
28     "Binomial": np.random.binomial(
29         n=10,
30         p=0.3,
31         size=100000
32     ),
33
34     "Normal": np.random.normal(
35         loc=0,
36         scale=1,
37         size=100000
```



```

38     )
39 }
40
41 for pop_name, population in populations.items():
42     fig, axes = plt.subplots(
43         2, 4,
44         figsize=(18, 8)
45     )
46
47     axes = axes.flatten()
48
49     for i, n in enumerate(sample_sizes):
50
51         sample_means = []
52
53         for _ in range(num_samples):
54
55             sample = np.random.choice(
56                 population,
57                 size=n,
58                 replace=True
59             )
60
61             sample_means.append(
62                 np.mean(sample)
63             )
64
65             sns.histplot(
66                 sample_means,
67                 bins=30,
68                 kde=True,
69                 ax=axes[i]
70             )
71
72             axes[i].set_title(f"n = {n}")
73
74

```

```
75     fig.suptitle(  
76         f"TCL - População {pop_name}",  
77         fontsize=16  
78     )  
79  
80     plt.tight_layout()  
81     plt.show()
```